وزارت علوم، تحقیقات و فناوری

دانشگاه شاهد

دانشکده علوم پایه

پایان‌نامه برای دریافت درجه کارشناسی ارشد

در رشته ریاضی، گرایش آنالیز عددی

حل مسئله مجموعه احاطه‌گر کامل با استفاده از شبکه‌های عصبی گرافی و یادگیری تقویتی

نگارنده:

محمود یوسفی

استاد راهنما:

جناب آقای دکتر نادر جعفری‌راد

استاد مشاور:

.....

ماه و سال:

.....

بِسْمِ اللهِ الرَّحْمنِ الرَّحيم

اظهارنامه دانشجو

اینجانب محمود یوسفی دانشجوی دوره کارشناسی ارشد رشته ریاضی گرایش آنالیز عددی دانشگاه شاهد، اظهار می‌دارم که این پایان‌نامه با عنوان «حل مسئله مجموعه احاطه‌گر کامل با استفاده از شبکه‌های عصبی گرافی و یادگیری تقویتی» بر پایه پژوهش‌های انجام‌شده توسط اینجانب و با راهنمایی استادان راهنما و مشاور، تهیه و تنظیم شده است، و کلیه حقوق مادی و معنوی آن متعلق به دانشگاه شاهد است. همچنین اعلام می‌دارم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی خودم است و در موارد استفاده از منابع دیگران، به آن‌ها ارجاع داده شده است.

نام و نام خانوادگی: محمود یوسفی

تاریخ و امضا: .....

تقدیم

به پدر و مادرم که آموختند پرسش، آغاز دانستن است.

سپاسگزاری

بدین‌وسیله از استاد راهنما، جناب آقای دکتر نادر جعفری‌راد، برای راهنمایی‌های دقیق در طول انجام این پژوهش سپاسگزاری می‌کنم. همچنین از همه کسانی که در مراحل اجرای آزمایش‌ها و بازبینی نتایج این کار یاری رساندند، قدردانی می‌کنم.

چکیده

مسئله مجموعه احاطه‌گر کامل یک تعمیم سخت‌گیرانه از مسئله مجموعه احاطه‌گر است که در آن هر رأس گراف باید حداقل یک همسایه در مجموعه انتخابی داشته باشد. در این پایان‌نامه، چارچوب یادگیری‌محور مبتنی بر شبکه عصبی گرافی و یادگیری تقویتی که توسط Chen و همکاران برای مسئله مجموعه احاطه‌گر ارائه شده است، بازسازی و سپس به مسئله کامل گسترش داده می‌شود. بازسازی پویاسازی مسئله به‌صورت یک فرآیند تصمیم‌گیری، محیط جدید و DDQN انجام شد و نتایج مقاله در جدول‌های مرجع بازتولید گردید. پرسش اصلی این بود که آیا اجزای همین چارچوب برای مسئله کامل قابل استفاده‌اند. پاسخ منفی است و در قالب یک قضیه اثبات می‌شود: ماسک عمل روش مرجع هرگز جواب شدنی برای مسئله کامل تولید نمی‌کند (این نتیجه با آزمایش روی ۱۷۷ گراف و یک مثال نقض کمینه روی مسیر چهاررأسی تأیید می‌شود). بنابراین فضای عمل بازطراحی شد: انتخاب یک رأس فقط همسایه‌های آن را راضی می‌کند، حالت محیط دو کاناله (coverage و selection) می‌شود و تابع پاداش از «سود پوشش» به «هزینه هر تصمیم» تغییر می‌کند؛ دلیل این تغییر با یک قضیه نشان داده می‌شود: پاداش مقاله در مسئله کامل بازدهی ثابت n تولید می‌کند و هیچ سیگنالی برای کمینه‌سازی اندازه ندارد. افزون بر این، سه بهبود ارائه و ارزیابی شد: رفع یک باگ مقیاس‌پذیری در خوانش گراف (که باعث انفجار مقادیر ارزش بر حسب اندازه گراف می‌شد)، مجاز کردن رأس‌های پشتیبان برگ به‌عنوان بخشی از جواب به‌جای حذف آن‌ها و دو تقویت «صفر-آموزش» شامل پالایش خروجی و ماسک top-k بر پایه سود. ارزیابی روی ۱۶۸ گراف از هفت خانواده نشان می‌دهد روش پیشنهادی از نظر آماری هم‌سطح بازارزیابی GRASP است ولی حدود ۴ تا ۲۵ برابر سریع‌تر جواب می‌دهد، روی لاتیس شش‌گوش به‌طور معنادار بهتر از آن عمل می‌کند (0.786 در برابر 0.847 نسبت به خط مبنای حریصانه) و روی لاتیس و خانواده‌های اسپارس به بهینه می‌رسد. همچنین اجبار برگ‌ها تعداد تصمیم‌های عامل را حدود ٪۶۴ و زمان رسیدن به سطح نهایی را حدود ۵.۳ برابر کاهش می‌دهد، بدون تغییر در کیفیت جواب.

واژه‌های کلیدی: مجموعه احاطه‌گر کامل، شبکه عصبی گرافی، یادگیری تقویتی، DDQN، بهینه‌سازی ترکیبیاتی، پوشش مجموعه‌ای، بازارزیابی GRASP.

فهرست مطالب

اظهارنامه دانشجو ب

تقدیم پ

سپاسگزاری ت

۱ گسترش چارچوب به مسئله مجموعه احاطه‌گر کامل ۱

۱-۱ مقدمه و صورت مسئله ۱

۱-۲ ساخت دومرحله‌ای و کران $2|D|$ ۲

۱-۳ چرا ماسک عمل مقاله برای TDSP کار نمی‌کند؟ ۲

۱-۴ محیط بازطراحی‌شده: فضای عمل TDSP ۴

۱-۵ تابع پاداش: از «سود» به «هزینه هر تصمیم» ۵

۱-۶ معماری شبکه: یک باگ مقیاس‌پذیری و رفع آن ۵

۱-۷ دانش گراف: قواعد کاهش و اجبار برگ‌ها ۶

۱-۸ الگوریتم یادگیری: از DDQN به سر دوگانه ۸

۱-۹ دو تقویت صفر-آموزش ۹

۱-۹-۱ پالایش خروجی (remove-redundant) ۹

۱-۹-۲ ماسک top-k بر پایه سود ۱۰

۱-۱۰ ارزیابی جامع ۱۰

۱-۱۱ مثال گام‌به‌گام: کل فرآیند روی یک گراف کوچک ۱۲

۱-۱۲ تهدیدهای اعتبار ۱۳

۲ نتیجه‌گیری و پیشنهادها ۱۵

۲-۱ خلاصه مسیر انجام پژوهش ۱۵

۲-۲ پاسخ به سؤالات تحقیق ۱۵

۲-۳ مشارکت‌های پژوهش ۱۵

۲-۴ قلمرو روش: کجا مفید است و کجا نیست ۱۶
۲-۵ محدودیت‌ها ۱۷
۲-۶ پیشنهادهای کارهای آینده ۱۷

منابع ۱۹

واژه‌نامه فارسی به انگلیسی ۲۰

فهرست شکل‌ها

۱-۱ کیفیت ساخت دومرحله‌ای ($|S|/\gamma_t$) به تفکیک خانواده گراف و منبع مجموعه D. خط‌چین، مرز بهینگی است. ۳

۱-۲ خروجی ماسک مقاله روی TDSP: همه اجراها مجموعه مستقل‌اند و هیچ‌کدام احاطه‌کننده کامل نیست. ۳

۱-۳ مثال نقض روی P_4: (الف) گراف؛ (ب) خروجی ماسک مقاله ($S = \{1, 3\}$) که احاطه‌گر کامل نیست؛ (ج) جواب بهینه $\{1, 2\}$ با همان اندازه. ۴

۱-۴ اثر رفع باگ مقیاس‌پذیری خوانش گراف بر کیفیت مدل. ۶

۱-۵ تعداد تصمیم‌های عامل به‌ازای هر گراف، با و بدون اجبار برگ‌ها. ۷

۱-۶ چپ: همگرایی DDQN و D3QN با □□□□ یکسان. راست: اثر اجبار برگ روی میانگین سه □□□□ با نوار کمینه□بیشینه. ۸

۱-۷ اثر remove-redundant روی خروجی چهار checkpoint. ۹

۱-۸ جاروب ماسک top-k: نسبت اندازه به حریصانه بر حسب k. ۱۰

۱-۹ کیفیت نسبت به حریصانه به تفکیک خانواده (میانگین $\pm$ خطای معیار). ۱۱

۱-۱۰ خانواده شش‌گوش: تنها خانواده‌ای که سیاست به‌طور معنادار از بازارزیابی بهتر است. ۱۲

۱-۱۱ کیفیت در برابر زمان استنتاج هر گراف (محور زمان لگاریتمی). ۱۲

۱-۱۲ اجرای گام‌به‌گام روی درخت $n = 12$: (الف) نشاندن F؛ (ب) پس از یک تصمیم شبکه؛ (ج) مجموعه نهایی. ۱۳

فهرست جدول‌ها

۱-۱ دو تابع پاداش روی مثال گراف درختی $n = 12$ (بخش ۱-۱۱) ۵

۱-۲ اثر اجبار برگ‌ها روی کیفیت و تعداد تصمیم (درخت تصادفی یکنواخت) ۷

۱-۳ مقایسه‌های زوجی روی گراف‌های متراکم و اسپارس (معیار $|S|/|greedy|$) ۱۱

۱-۲ پاسخ فشرده به سؤالات پژوهش و شاهد هر پاسخ ۱۶

فصل ۱

گسترش چارچوب به مسئله مجموعه احاطه‌گر کامل

۱-۱ مقدمه و صورت مسئله

فصل چهارم چارچوب مرجع Chen و همکاران را بازسازی کرد؛ در آن چارچوب، مسئله مجموعه احاطه‌گر (DSP) حل می‌شود: زیرمجموعه‌ای از رأس‌ها انتخاب می‌شود که هر رأس گراف یا خود در آن مجموعه باشد یا حداقل یک همسایه در آن داشته باشد. پرسش این فصل، نسخه سخت‌گیرانه‌تر همان مسئله است.

تعریف ۱-۱ (مجموعه احاطه‌گر کامل). برای گراف بدون جهت $G = (V, E)$، مجموعه $S \subseteq V$ یک مجموعه احاطه‌گر کامل (TDS) است اگر هر رأس $v \in V$ حداقل یک همسایه در S داشته باشد:

$$\forall v \in V : \quad N(v) \cap S \neq \emptyset. \tag{۱-۱}$$

عدد احاطه‌گری کامل $\gamma_t(G)$ کمینه اندازه چنین مجموعه‌ای است.

تفاوت با DSP در یک واژه است: در DSP رأس می‌تواند «خودش» نیاز را برآورده کند، اما در TDSP باید همسایه‌ای درون مجموعه داشته باشد. سه پیامد فوری این تفاوت:

۱. هیچ رأس منزوی نمی‌تواند در جوابی معتبر حضور داشته باشد؛ بنابراین گراف باید درجه کمینه حداقل یک داشته باشد و در محاسبات این فصل گراف‌های دارای رأس منزوی کنار گذاشته می‌شوند.

۲. هر عضو S باید «پشتیبان» داشته باشد: رأسی که آن را احاطه کند. پس خروجی نمی‌تواند مجموعه‌ای مستقل باشد.

۳. شرط پایان فرآیند تصمیم‌گیری عوض می‌شود: در DSP پایان یعنی «همه رأس‌ها پوشش داده شده‌اند»؛ در TDSP یعنی «همه رأس‌ها همسایه‌ای در S دارند»، و این دو نه‌فقط متفاوت، بلکه برای رأس‌های عضو مجموعه ناسازگارند.

هر دو مسئله NP-سخت‌اند و در ادبیات، TDSP معادل دقیق یک مسئله پوشش مجموعه‌ای است: جهان، مجموعه

رأس‌هاست و برای هر رأس u یک مجموعه $N(u)$ تعریف می‌شود؛ انتخاب u تمام اعضای $N(u)$ را می‌پوشاند. این مشاهده، هم خط مبنای قوی فصل (الگوریتم GRASP) را ممکن می‌کند و هم پالایش خروجی در بخش ۱-۹ را.

معیارهای ارزیابی این فصل: اندازه خروجی نسبت به بهینه γ_t و نسبت به خط مبنای حریصانه، نسبت به بازارزیابی (GRASP)، نرخ شدنی‌بودن، تعداد تصمیم‌های عامل و زمان استنتاج.

۱-۲ ساخت دومرحله‌ای و کران $2|D|$

اولین پرسش طبیعی این است: آیا می‌توان TDSP را از DSP ساخت؟ اگر D یک مجموعه احاطه‌گر معمولی باشد، آیا می‌توان از آن یک مجموعه احاطه‌گر کامل ساخت؟

برای هر D یک زیرمجموعه $A \subseteq D$ با این خاصیت انتخاب می‌کنیم که هر عضو D حداقل یک همسایه در A داشته باشد (مسئله‌ای در اندازه خودِ D)، و $S = A \cup (V \setminus D)$ را برمی‌گردانیم.

قضیه ۱-۱. برای هر مجموعه احاطه‌گر D از گرافی بدون رأس منزوی، مجموعه $S = A \cup (V \setminus D)$ یک مجموعه احاطه‌گر کامل است و

$$|S| \le 2|D|. \tag{۱-۲}$$

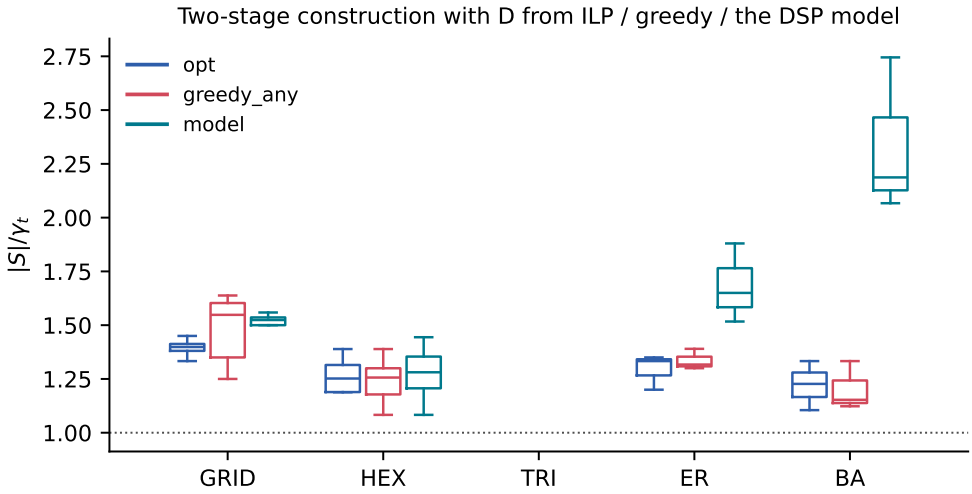
اثبات. هر $u \in V \setminus D$ چون D احاطه‌کننده است، همسایه‌ای در D دارد و همان همسایه در S حضور دارد (چون $A \subseteq S$). هر $u \in D$ بنا به تعریف A همسایه‌ای در $A \subseteq S$ دارد. پس شرط (۱-۱) برای همه رأس‌ها برقرار است. برای اندازه: $|S| \le |A| + |V \setminus D| \le |D| + (n - |D|)$؛ کران را نمی‌توان با این استدلال دقیق‌تر کرد، ولی در گراف‌های چگال $|V \setminus D|$ کوچک است و کران عملاً شل می‌ماند. □

شکل ۱-۱ کیفیت این ساخت را به‌ازای سه منبع برای D نشان می‌دهد: حل دقیق، حریصانه، و شبکه فصل چهارم. نتیجه‌ها دو نکته را روشن می‌کنند: نخست، کران (۱-۲) در هیچ نمونه‌ای نقض نشد (با assert روی همه گراف‌ها بررسی شد)؛ دوم، کیفیت میانی بسیار بدتر از کران است، به‌ویژه روی گراف‌های BA که $|D|$ بزرگ است و D مستقل، خروجی را تا حدود $2.7\gamma_t$ می‌برد. به زبان دیگر، مزیت این مسیر «تضمین» است، نه «کیفیت»؛ و همین مشاهده ما را به بازطراحی مستقیم فضای عمل سوق داد.

۱-۳ چرا ماسک عمل مقاله برای TDSP کار نمی‌کند؟

در چارچوب مرجع، عمل مجاز فقط رأسی است که هنوز احاطه نشده باشد ($v f_v = 0$)، و انتخاب v خودِ v و همسایه‌هایش را «احاطه‌شده» علامت می‌زند. از این دو قاعده یک نتیجه ساختاری به‌دست می‌آید.

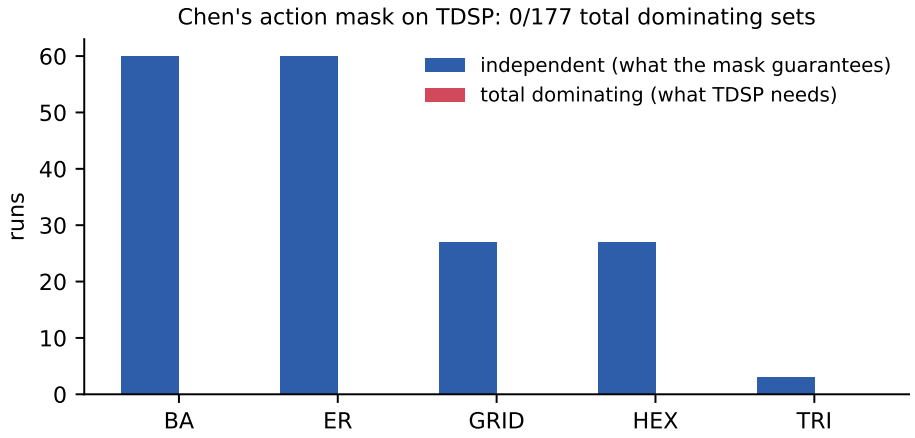
قضیه ۱-۲ (ناسازگاری ماسک). هر اجرای کامل سیاست مقاله (با هر قاعده انتخاب، تصادفی یا حریصانه) مجموعه‌ای مستقل تولید می‌کند، و بنابراین هیچ‌گاه یک مجموعه احاطه‌گر کامل نیست.



شکل ۱-۱: کیفیت ساخت دومرحله‌ای ($|S|/\gamma_t$) به تفکیک خانواده گراف و منبع مجموعه D. خط‌چین، مرز بهینگی است.

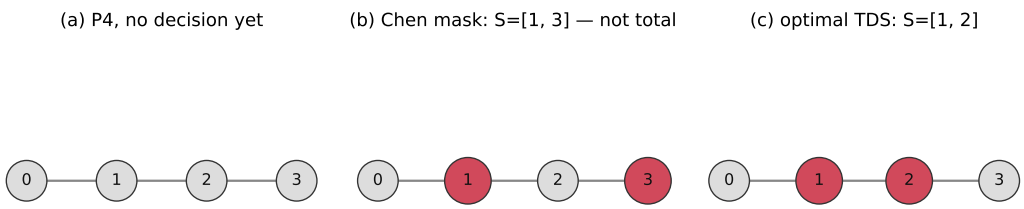
اثبات. فرض کنید $u, v \in S$ و $\{u, v\} \in E$. چون v با انتخاب u احاطه شده است، $vf_v = 1$ می‌شود و در گام‌های بعدی v از مجموعه اعمال مجاز حذف می‌شود؛ پس v نمی‌تواند انتخاب شود. این با $v \in S$ در تناقض است؛ بنابراین S مستقل است. در مجموعه مستقل، هیچ عضو S همسایه‌ای در S ندارد، پس شرط (۱-۱) برای اعضای S برقرار نمی‌شود. □

شکل ۱-۲ این قضیه را تجربی تأیید می‌کند: روی ۱۷۷ گراف از پنج خانواده، هر سه سیاست (تصادفی، حریصانه، مدل آموزش‌دیده) خروجی مستقل دادند و هیچ خروجی احاطه‌گر کامل نبود. این نتیجه یک تفاوت مهم با «بدتر بودن عملکرد» دارد: مسئله اینجا ناشدنی بودن است، نه کیفیت پایین. پس نمی‌توان ماسک مقاله را بدون تغییر به TDSP منتقل کرد.



شکل ۱-۲: خروجی ماسک مقاله روی TDSP: همه اجراها مجموعه مستقل‌اند و هیچ‌کدام احاطه‌کننده کامل نیست.

کوچک‌ترین مثال نقض، مسیر P_4 با رأس‌های $0 - 1 - 2 - 3$ است. سیاست ماسک‌دار حریصانه $S = \{1, 3\}$ را می‌سازد؛ این مجموعه احاطه‌گر است و اندازه‌اش هم 2 است، اما رأس 3 هیچ همسایه‌ای در S ندارد، چون تنها همسایه‌اش (2) عضوی از مجموعه نیست. در همین گراف، جواب بهینه مجموعاً برابر 2 است ولی با ترکیب دیگری ($S^* = \{1, 2\}$). شکل ۱-۳ این مغایرت را نشان می‌دهد: تفاوت در اندازه نیست، در شدنی‌بودن است.



شکل ۱-۳: مثال نقض روی P_4: (الف) گراف؛ (ب) خروجی ماسک مقاله ($S = \{1, 3\}$) که احاطه‌گر کامل نیست؛ (ج) جواب بهینه $\{1, 2\}$ با همان اندازه.

۱-۴ محیط بازطراحی‌شده: فضای عمل TDSP

بر اساس بخش ۱-۳، سه قاعده چارچوب مرجع بازنویسی می‌شود:

۱. ماسک: هر رأسی که هنوز در S نیست مجاز است (نه فقط رأس‌های احاطه‌نشده). بنابراین اعضای S می‌توانند همسایه یکدیگر باشند.

۲. گذار: انتخاب v فقط $N(v)$ را «راضی» می‌کند و خودِ v راضی نمی‌شود؛ پس vf_v تا زمانی که همسایه‌ای انتخاب نشود صفر می‌ماند. این قاعده، قید احاطه‌گری کامل را به‌صورت بومی در مکانیک مسئله می‌نشاند.

۳. پایان: فرآیند وقتی پایان می‌یابد که همه رأس‌ها $vf = 1$ باشند، یعنی هر رأس همسایه‌ای در S داشته باشد.

از آنجا که در مسئله جدید «عضو بودن» و «احاطه‌شده بودن» دو چیز متفاوت‌اند، حالت محیط باید دو کانال داشته باشد:

$$s = \big[\, vf \parallel ins \,\big] \in \{0,1\}^{n\times 2}, \qquad vf_u = \mathbb{I}\big[N(u) \cap S \neq \emptyset\big], \qquad ins_u = \mathbb{I}\big[u \in S\big]. \quad (۳-۱)$$

اگر تنها vf به شبکه داده شود، دو وضعیت متمایز (رأسی که انتخاب شده ولی هنوز راضی نشده، و رأسی که نه انتخاب شده و نه راضی است) یکسان دیده می‌شوند و سیاست نمی‌تواند میان آن‌ها تفکیک کند. شکل ۱-۱۲ (الف) و (ب) همین دو کانال را روی یک مثال نشان می‌دهد.

نکته مهم برای بازتولید: رابط محیط ($reset/candidates/step$) عوض نشده است؛ فقط قواعد و ابعاد حالت تغییر کرده‌اند. بنابراین حلقه یادگیری، شبکه پیام‌رسان و مکانیزم DDQN فصل چهارم بدون بازنویسی روی محیط جدید کار می‌کنند؛ تنها شرط آن است که نامزدها از خود محیط خوانده شوند (نه از $vf = 0$) و شبکه $in - ch = 2$ بگیرد. سه آزمون مستقل این تطبیق را تأیید کرد: ۱۱۸ بررسی مکانیک، هم‌ارزی سیاست حریصانه محیط با greedy بومی در ۵۹ از ۵۹ نمونه، و بازتولید خط‌به‌خط نتایج DSP فصل چهارم با نسخه پیشین کد (آزمون عدم رگرسیون).

۱-۵ تابع پاداش: از «سود» به «هزینه هر تصمیم»

پاداش چارچوب مرجع بر پایه تعداد رأس‌های تازه‌احاطه‌شده تعریف می‌شود. روی TDSP این تعریف یک اشکال ساختاری پیدا می‌کند.

قضیه ۱-۳. اگر پاداش هر گام برابر تعداد رأس‌هایی باشد که با انتخاب آن گام تازه راضی می‌شوند (پاداش سود، یا نسخه ± 1 مقاله)، بازدهی هر اپیزود مستقل از سیاست و از اندازه مجموعه نهایی است.

اثبات. شرط پایان محیط این است که همه رأس‌ها $vf = 1$ شوند. هر رأس در پایان اپیزود دقیقاً یک‌بار «تازه راضی‌شده» شمرده می‌شود؛ بنابراین مجموع سود در طول اپیزود همیشه برابر n است و بازده n (یا ترکیب خطی ثابت از n) می‌شود، مستقل از $|S|$. □

نتیجه: عاملی که این پاداش را بیشینه می‌کند هیچ انگیزه‌ای برای کوچک کردن $|S|$ ندارد؛ همه سیاست‌ها بازده یکسان می‌گیرند و سیگنال بهینه‌سازی از بین می‌رود.

تعریف ۱-۲ (پاداش هزینه). در هر تصمیم عامل پاداش $r = -1$ می‌گیرد. بنابراین بازده اپیزود برابر $-|$تصمیم‌های عامل$|$ است، و اگر مجموعه اجباری F (بخش ۱-۷) از پیش در S باشد، بازده کل برابر $-|S|$ می‌شود.

جدول ۱-۱ این تفاوت را روی مثال بخش ۱-۱۱ عددگذاری می‌کند. در سطح کل آزمایش‌ها، این تغییر ساده اثر چشمگیری داشت: میانگین $|S|/$□□□□□□ روی گراف‌های تصادفی بزرگ از 4.34 به 1.04 رسید و مدل از «شش برابر بدتر از حریصانه» به «هم‌سطح آن» تغییر کرد؛ روی لتیس‌های شش‌گوش، پاداش paper کمی بهتر از پاداش هزینه بود (0.812 در برابر 0.877).

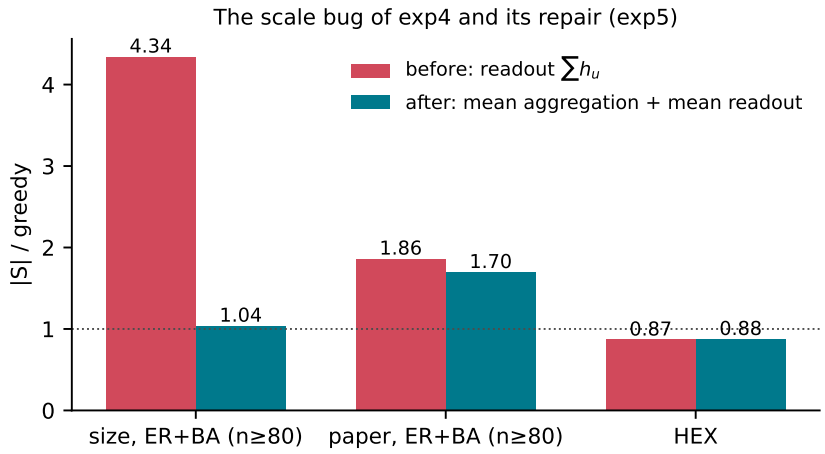
جدول ۱-۱: دو تابع پاداش روی مثال گراف درختی $n = 12$ (بخش ۱-۱۱)

پاداش	بازده اپیزود	ارتباط با هدف	سیگنال بهینه‌سازی
سود (نسخه مقاله)	$+12$	مستقل از $\lvert S\rvert$	ندارد
هزینه ($r = -1$)	-6	دقیقاً $-\lvert S\rvert$	دارد

۱-۶ معماری شبکه: یک باگ مقیاس‌پذیری و رفع آن

خوانش گراف در چارچوب مرجع، جمع نمایش رأس‌ها است: $s = \sum_u h_u$. این تعریف برای n ثابت بی‌ضرر است، ولی وقتی مدل فقط روی $n = 20$ آموزش می‌بیند و روی اندازه‌های دیگر آزمون می‌شود، فاجعه‌بار می‌شود: اندازه خروجی خوانش با n رشد می‌کند و مقادیر Q منفجر می‌شوند. اندازه‌گیری ما: در $n = 20$ مقدار $Q \approx 0.8$ بود و در $n = 300$ به 85183 می‌رسید. این باگ در مسئله DSP نیز وجود داشت ($Q \approx 76379$ در $n = 500$)، ولی چون مقاله برای هر اندازه یک مدل جدا آموزش می‌دهد، در گزارش اصلی آشکار نشده است.

رفع باگ دو تغییر کوچک است: تابع تجمیع پیام‌ها از جمع به میانگین (□□□□ = □□□□) و خوانش گراف از $\sum h_u$ به $\frac{1}{n}\sum h_u$ (□□□□-□□□□□□□). پس از این تغییر، Q برای همه اندازه‌ها تقریباً ثابت می‌ماند (≈ 0.09) و تعمیم به اندازه‌های آموزش‌ندیده ممکن می‌شود. شکل ۱-۴ اثر این اصلاح را نشان می‌دهد: روی گراف‌های تصادفی با $n \geq 80$ کیفیت مدل با پاداش هزینه از 4.34 به 1.04 بهبود می‌یابد و روی لتیس‌ها مدل بهتر از حریصانه می‌شود (0.81□0.88).



شکل ۱-۴: اثر رفع باگ مقیاس‌پذیری خوانش گراف بر کیفیت مدل.

۱-۷ دانش گراف: قواعد کاهش و اجبار برگ‌ها

نوآوری دوم پروپوزال، استفاده از مفاهیم نظریه گراف برای کاهش فضای جست‌وجو است. سه قاعده کلاسیک بررسی شد:

۱. رأس منزوی: تنها برای تشخیص ناشدنی‌بودن مفید است.

۲. مؤلفه‌های همبند: تجزیه دقیق است و مسئله را به مؤلفه‌ها می‌شکند.

۳. برگ و پشتیبان: در DSP معتبر است، اما در TDSP نامعتبر است.

قضیه ۱-۴ (نامعتبری قاعده برگ). در TDSP نمی‌توان رأس پشتیبان یک برگ و همسایگانش را از گراف حذف کرد و مسئله را روی گراف باقی‌مانده حل کرد.

اثبات. مثال نقض: مسیر P_3 با رأس‌های $2-1-0$. برگ 0 رأس 1 را اجباری می‌کند. با حذف $\{1\}\cup N(1) = \{0,1,2\}$ گراف خالی می‌ماند و جواب پیشنهادی $\{1\}$ است؛ اما 1 هیچ همسایه‌ای در مجموعه ندارد و احاطه‌گری کامل برقرار نیست. جواب بهینه $\{0,1\}$ با اندازه 2 است. علت ساختاری: در احاطه‌گری کامل، خودِ رأس پشتیبان هم باید پشتیبان داشته باشد، پس زیرمسئله، گراف القایی ساده نیست. □

پس قاعده برگ به شکل «حذف» بی‌اعتبار است. اما شکل مثبت همان ایده معتبر است: هر پشتیبانِ برگ در هر جواب معتبر حاضر است، چون تنها همسایه برگ خودش است و برگ باید توسط آن احاطه شود.

تعریف ۱-۳ (مجموعه اجباری). F را مجموعه پشتیبان‌های برگ‌ها بگیرید. چون هر برگ درجه یک دارد، پشتیبانش در هر مجموعه احاطه‌گر کامل حاضر است.

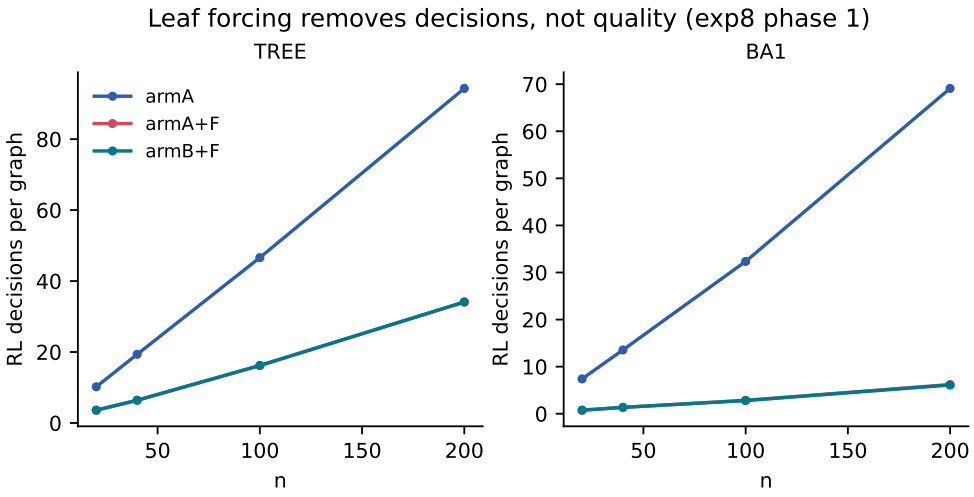
ایده اجرایی: به‌جای حذف رأس‌ها، F را در ابتدای اپیزود در S می‌نشانیم. مکانیک vf خودبه‌خود قید باقی‌مانده را حمل می‌کند: هر عضو F چون خودش هم باید پشتیبان داشته باشد، همچنان «راضی‌نشده» می‌ماند و عامل باید برایش همسایه انتخاب کند. پاداش هزینه فقط به تصمیم‌های عامل تعلق می‌گیرد و چون $|F|$ در هر جواب ثابت است، آفستی ثابت است و بهینه‌سازی را تغییر نمی‌دهد.

چرا این مسیر روی خانواده‌های متراکم بی‌اثر است؟ چون آن گراف‌ها برگ ندارند ($F = \emptyset$) و لتیس‌ها هم تک‌مؤلفه‌ای و بدون رأس منزوی‌اند؛ بنابراین قاعده‌های یک و دو هم فعال نمی‌شوند. یعنی قواعد کاهش کلاسیک در این دامنه سودی ندارند □ یک نتیجه منفی که صادقانه گزارش می‌شود. اما روی خانواده‌های اسپارس (درخت تصادفی و BA با $m = 1$) وضعیت فرق می‌کند: پوشش F تا حدود 30% رأس‌ها را می‌گیرد و صرفه‌جویی بزرگی در تعداد تصمیم ایجاد می‌کند.

جدول ۱-۲ و شکل ۱-۵ این صرفه‌جویی را نشان می‌دهند: روی درخت‌ها، تعداد تصمیم‌های عامل برای $n = 100$ از 46.6 به 16.2 و برای $n = 200$ از 94.3 به 34.1 می‌رسد (کاهش حدود 64%)، بدون آنکه کیفیت نهایی تغییر کند.

جدول ۱-۲: اثر اجبار برگ‌ها روی کیفیت و تعداد تصمیم (درخت تصادفی یکنواخت)

پیکربندی	$\lvert S\rvert/\gamma_t$ ($n = 100$)	تصمیم‌ها ($n = 100$)	$\lvert S\rvert/\gamma_t$ ($n = 200$)	تصمیم‌ها ($n = 200$)
سیاست آزاد	1.000	46.6	1.000	94.3
سیاست با F	1.000	16.2	1.000	34.1



شکل ۱-۵: تعداد تصمیم‌های عامل به‌ازای هر گراف، با و بدون اجبار برگ‌ها.

اثر اجبار روی همگرایی نیز اندازه‌گیری شد. در آزمایش زوجی با سه ،□□□□ هر دو بازو به کیفیت نهایی یکسان رسیدند (9.67 ± 0.15) اما بازوی دارای اجبار پس از $43{,}333 \pm 10{,}408$ اپیزود به این سطح رسید و بازوی بدون اجبار پس از $160{,}000 \pm 18{,}028$ اپیزود؛ یعنی حدود سه و نیم برابر سریع‌تر. این مقایسه زوجی است، چون با □□□□ یکسان هر دو

بازو دنباله یکسانی از گراف‌های آموزش، مقداردهی اولیه شبکه و برنامه ε می‌گیرند و تنها عامل تفاوت، خودِ اجبار است. نکته صادقانه: مدل آموزش‌دیده با اجبار باید در زمان آزمون هم با F اجرا شود؛ اگر بدون F اجرا شود، روی گراف‌های اسپارس از حریصانه بدتر عمل می‌کند.

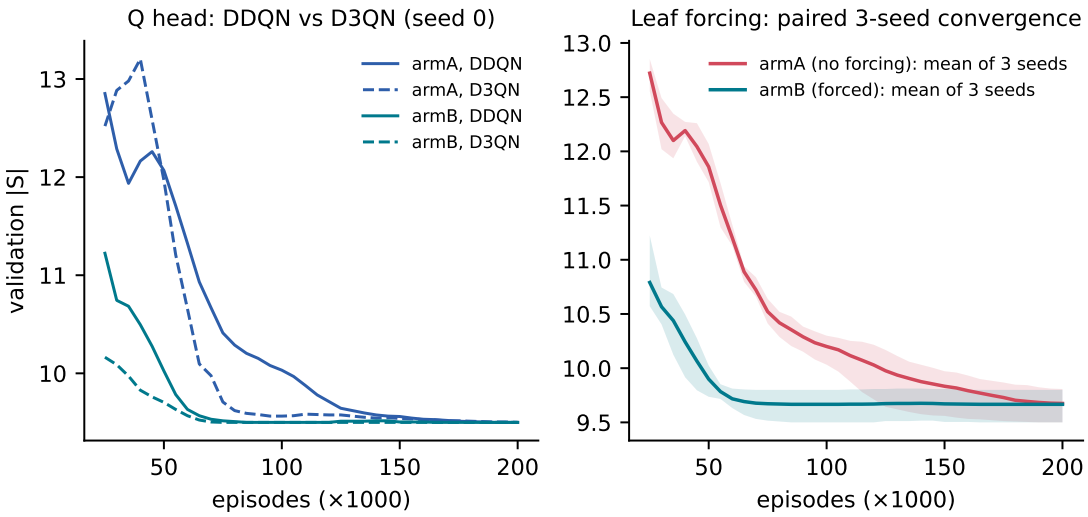
۸-۱ الگوریتم یادگیری: از DDQN به سر دوگانه

پس از تثبیت محیط، پاداش و گراف، پرسش بعدی این بود که آیا «الگوریتم یادگیری بهتر» چیزی اضافه می‌کند؟ کوچک‌ترین تغییر ممکن، سر دوگانه (Dueling) است که تابع ارزش را به دو بخش تجزیه می‌کند:

$$Q(s,v) = V(s) + A(s,v) - \frac{1}{|\mathcal{A}(s)|}\sum_{v' \in \mathcal{A}(s)} A(s,v'), \qquad (۴-۱)$$

که V ارزش حالت و A مزیت عمل است. محیط، پاداش، MPNN، قاعده به‌روزرسانی DDQN و پروتکل آموزش دست‌نخورده می‌مانند و فقط سر شبکه عوض می‌شود (فلگ dueling–، پیش‌فرض خاموش تا نتایج پیشین بی‌تغییر بمانند).

نتیجه غربالگری: کیفیت نهایی در هر چهار مقایسه زوجی عملاً یکسان است ($9.50/9.80/9.70/9.50$ در برابر $9.50/9.80/9.70/9.50$)، اما رسیدن به سطح فلات سریع‌تر می‌شود: میانگین سه □□□□ در بازوی آزاد از $150{,}000$ به $90{,}000$ اپیزود و در بازوی دارای اجبار از $45{,}000$ به $25{,}000$ اپیزود (حدود 1.7 برابر). شکل ۱-۶ (چپ) این تفاوت را نشان می‌دهد.



شکل ۱-۶: چپ: همگرایی DDQN و D3QN با □□□□ یکسان. راست: اثر اجبار برگ روی میانگین سه □□□□ با نوار کمینه□بیشینه.

حکم ما صریح است: D3QN «بهتر نیست، ارزان‌تر است». ارزش آن صرفه‌جویی در بودجه آموزش است، نه بهبود کیفیت پاسخ. همچنین باید توجه داشت که معیار «اپیزود رسیدن به سطح فلات» یک معیار آستانه‌ای است؛ در یکی از ها□□□□ که مقدار نهایی دقیقاً روی آستانه می‌نشیند، این معیار بی‌معنا می‌شود و عدد سرعت را نباید به‌عنوان سرعت دیواری

نقل کرد.

۱-۹ دو تقویت صفر-آموزش

تا اینجا هر بهبود هزینه آموزش داشت. پرسش آخر این بود: از های□□□□□□□□□□ موجود، بدون هیچ آموزش تازه، چقدر می‌توان گرفت؟ دو تقویت بررسی شد.

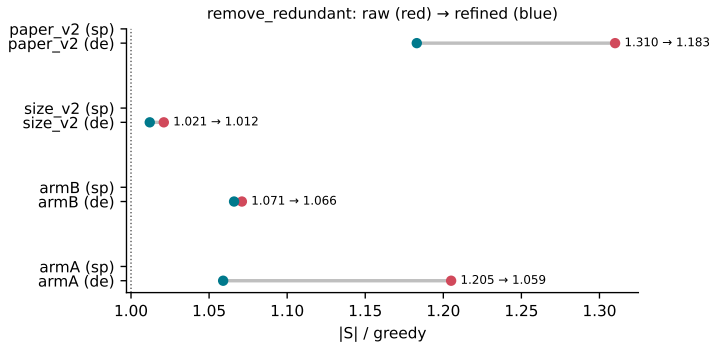
۱-۹-۱ پالایش خروجی (remove-redundant)

چون TDSP دقیقاً یک مسئله پوشش مجموعه‌ای است، پالایش کلاسیک روی هر جواب معتبر قابل اعمال است: اگر رأسی در S باشد که همه همسایه‌هایش توسط اعضای دیگر S پوشش داده می‌شوند، حذف آن جواب را از احاطه‌گری کامل خارج نمی‌کند.

لم ۱-۱. اگر S احاطه‌گر کامل باشد و $v \in S$ حذف شود، مجموعه حاصل احاطه‌گر کامل است به شرط آنکه هر $u \in N(v)$ عضوی از $S \setminus \{v\}$ داشته باشد. بنابراین اندازه هرگز افزایش نمی‌یابد و خروجی همیشه شدنی می‌ماند.

اثبات. برای هر $u \in N(v)$، همسایه‌ای در $S \setminus \{v\}$ موجود است (فرض لم). برای سایر رأس‌ها، شاهدان پیشین دست‌نخورده‌اند چون تنها v حذف شده و v شاهد هیچ رأسی جز همسایه‌هایش نبود. □

در پیاده‌سازی، این شرط نه فرض، بلکه خودِ آزمون است: پس از هر حذف بررسی می‌شود که مجموعه همچنان احاطه‌گر کامل است، و همچنین assert می‌شود که اندازه زیاد نشود. اثر عملی چشمگیر بود (شکل ۱-۷): روی گراف‌های متراکم، armA از 1.205 به 1.059 (حدود 12% کوچک‌تر؛ در 55% نمونه‌ها حداقل یک رأس حذف شد) و paper-v2 از 1.310 به 1.183 بهبود یافت. روی گراف‌های اسپارس اثر تقریباً صفر است، چون مجموعه‌های مدل از پیش کمینه‌اند.



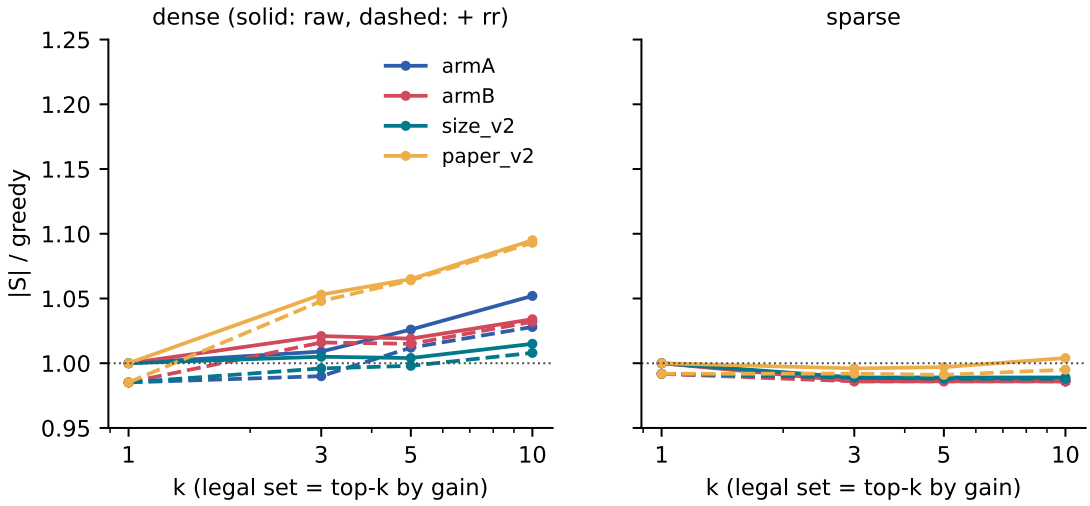
شکل ۱-۷: اثر remove-redundant روی خروجی چهار checkpoint.

همین پالایش یک ایراد روش‌شناختی در مقایسه‌های پیشین را آشکار کرد: در آزمایش بازارزیابی، GRASP درون خود این پالایش را دارد، در حالی که مدل با خروجی خام سنجیده می‌شد. پس از متقارن کردن این شرط، فاصله مدل و GRASP به‌شدت کم شد و ادعای «مدل به GRASP می‌بازد» به «هم‌سطح» تغییر کرد.

۱-۹-۲ ماسک top-k بر پایه سود

در هر گام، به‌جای آنکه سیاست در میان همه رأس‌های مجاز انتخاب کند، فقط k رأسِ با بیشترین سود (تعداد همسایه‌های راضی‌نشده) قانونی اعلام می‌شوند و شبکه میان آن‌ها انتخاب می‌کند. دو سر این طیف از پیش معلوم است: $k = 1$ دقیقاً سیاست حریصانه بومی است و $k = n$ همان سیاست آزاد. این تقویت، تعمیم عملی همان ایده «اولویت‌گذاری نامزدها» است که در طرح اولیه دنبال می‌کردیم.

شکل ۱-۸ نتیجه جاروب را نشان می‌دهد: $k = 3$ بهترین است ($1.009 \rightarrow 1.205$ برای armA) و افزایش k به 5 و 10 بدتر می‌شود. تفسیر: سود از «حذف گزینه‌های کم‌سود» می‌آید، نه از آزادی بیشتر؛ یعنی سیاست در گام‌هایی که یک رأس کم‌سود را ترجیح می‌دهد اشتباه می‌کند. ترکیب $k = 3$ با پالایش خروجی، مدل را به سطح GRASP می‌رساند.



شکل ۱-۸: جاروب ماسک top-k: نسبت اندازه به حریصانه بر حسب k.

برای آنکه ادعای «هوشمندی سیاست» با «کمک ماسک حریصانه» اشتباه نشود، دو کنترل افزوده شد: (الف) greedy+rr، یعنی همان پالایش روی سیاست بی‌هوش؛ (ب) random@k+rr، یعنی سکه‌انداختن در همان مجموعه k رأسی. نتیجه روی گراف‌های متراکم: armA@3+rr برابر 0.990، random@3+rr برابر 1.099 و greedy+rr برابر 0.995؛ یعنی شبکه در همان مجموعه قانونی 11 واحد بهتر از سکه‌انداختن عمل می‌کند، ولی نسبت به حریصانه پالایش‌شده تقریباً هم‌سطح است.

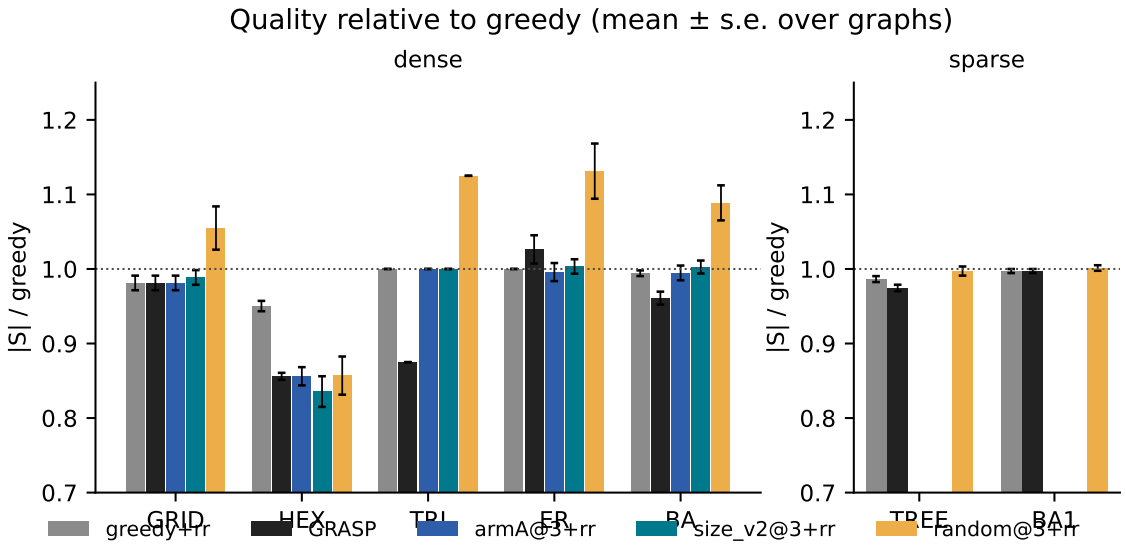
۱-۱۰ ارزیابی جامع

ارزیابی این فصل روی ۱۶۸ نمونه گراف انجام شد: ۸۸ گراف متراکم (شبکه مستطیلی، شش‌گوش، مثلثی و ER/BA تا $n = 300$) و ۸۰ گراف اسپارس (درخت تصادفی و BA با $m = 1$ تا $n = 200$)، با چهار checkpoint و ۶۸۸۸ مجموعه تولیدشده. همه مجموعه‌های تولیدشده یک‌بار دیگر به‌عنوان احاطه‌گر کامل بررسی شدند: هیچ خروجی ناشدنی وجود نداشت، هیچ‌گاه remove-redundant اندازه را افزایش نداد و ماسک با $k = 1$ در ۱۶۸ از ۱۶۸ نمونه دقیقاً همان جواب حریصانه بومی را داد (شاهد درستبودن پیاده‌سازی).

شکل ۱-۹ کیفیت را نسبت به حریصانه به تفکیک خانواده نشان می‌دهد و جدول ۱-۳ نتیجه آزمون‌های زوجی را خلاصه می‌کند. آزمون‌ها روی گراف‌های جفت‌شده (یک شناسه برای هر گراف) انجام شده‌اند: بازه اطمینان بوت‌استرپ با ۱۰۰۰۰ بازنمونه‌گیری و آزمون ویلکاکسون علامت‌دار.

جدول ۱-۳: مقایسه‌های زوجی روی گراف‌های متراکم و اسپارس (معیار $|S|/|greedy|$)

مقایسه	تفاوت میانگین	بازه اطمینان ۹۵٪	p	حکم
armA@3+rr در برابر greedy+rr	-0.0049	$[-0.019, +0.010]$	0.485	تساوی
armA@3+rr در برابر GRASP	$+0.0026$	$[-0.017, +0.023]$	0.851	تساوی
armA@3+rr در برابر random@3+rr	-0.109	$[-0.150, -0.071]$	1.5×10^{-7}	شبکه مؤثر است
armA در برابر armA@3	$+0.196$	$[+0.155, +0.239]$	2×10^{-11}	ماسک مؤثر است
armA در برابر armA+rr	$+0.145$	$[+0.110, +0.183]$	2×10^{-9}	پالایش مؤثر است
armB@3+rr در برابر greedy+rr	$+0.022$	$[+0.004, +0.041]$	0.035	اندکی بدتر
armA+F در برابر GRASP (اسپارس)	$+0.0001$	$[0, +0.0004]$	0.317	تساوی

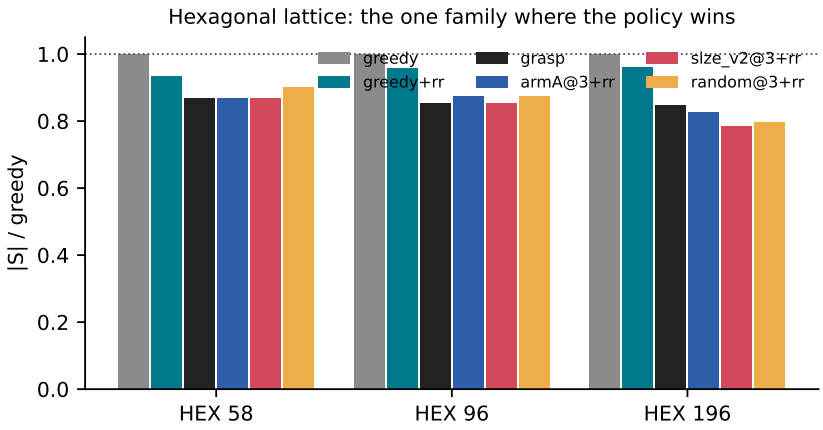


شکل ۱-۹: کیفیت نسبت به حریصانه به تفکیک خانواده (میانگین $\pm$ خطای معیار).

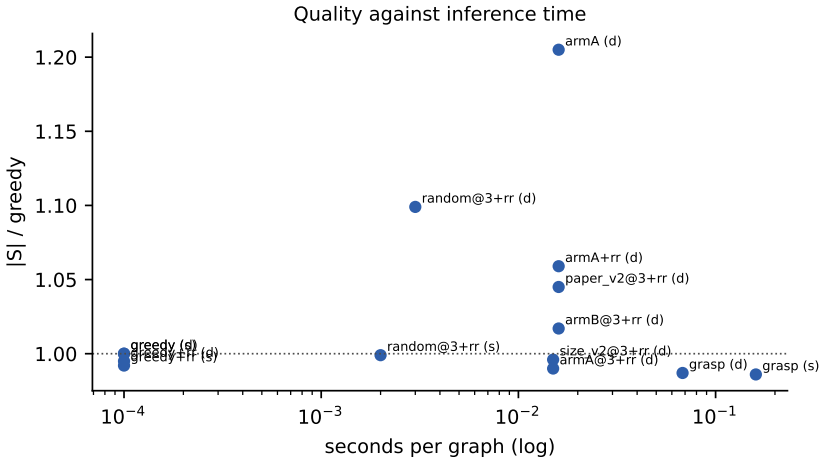
جمع‌بندی کمّی:

- روی گراف‌های تصادفی متراکم، پیکربندی پیشنهادی (armA@3+rr) با بازارزیابی GRASP آماری هم‌سطح است و از حریصانه پالایش‌شده هم بهتر نیست؛ برتری واقعی در این خانواده وجود ندارد و صادقانه گزارش می‌شود.
- روی گراف‌های اسپارس، مدل به بهینه می‌رسد ($|S|/\gamma_t = 1.000$) برای هر دو بازوی آموزش‌دیده) و از greedy+rr به‌طور آماری بهتر است ($p = 4 \times 10^{-4}$)، هرچند اختلاف اندازه ناچیز است.
- روی لاتیس شش‌گوش، مدل واقعاً برنده است: بهترین نتیجه فصل size-v2@3+rr با نسبت 0.786 در برابر GRASP با 0.847 و حریصانه پالایش‌شده با 0.959 (شکل ۱-۱۰).

- هزینه: مدل با تقویت‌ها روی گراف‌های متراکم حدود 0.015 ثانیه و روی اسپارس 0.005–0.007 ثانیه زمان می‌برد، در برابر 0.068 ثانیه (GRASP روی متراکم) و 0.163 ثانیه (روی اسپارس)؛ یعنی حدود 4 تا 25 برابر سریع‌تر با کیفیت هم‌سطح (شکل ۱-۱۱).



شکل ۱-۱۰: خانواده شش‌گوش: تنها خانواده‌ای که سیاست به‌طور معنادار از بازارزیابی بهتر است.



شکل ۱-۱۱: کیفیت در برابر زمان استنتاج هر گراف (محور زمان لگاریتمی).

۱-۱۱ مثال گام‌به‌گام: کل فرآیند روی یک گراف کوچک

برای اینکه خواننده بتواند همه اجزای بخش‌های پیشین را یک‌جا ببیند، فرآیند را روی یک درخت تصادفی با $n = 12$ رأس (پنج) گام‌به‌گام اجرا می‌کنیم. برگ‌های این درخت $\{1, 2, 3, 4, 11\}$ و مجموعه اجباری $F = \{0, 6, 8, 10\}$ است.

گام صفر (اجبار). F در S نشانده می‌شود. بنابراین $vf = 1$ برای همه همسایه‌های F، و برای خود اعضای F مقدار vf صفر می‌ماند، چون هنوز کسی آن‌ها را احاطه نکرده است. این همان تفکیک دو کانال حالت (۱-۳) است: ins برای اعضای F یک و vf صفر است. شکل ۱-۱۲ (الف).

گام یک (تصمیم شبکه). نامزدهای قانونی همه رأس‌های خارج از S هستند: $\{1,2,3,4,5,7,9,11\}$. سود هر نامزد (تعداد همسایه‌های راضی‌نشده) محاسبه می‌شود؛ در این گام، رأس‌های $2,3,4$ بزرگ‌ترین سود (1) را دارند، پس با $k=3$ همان‌ها قانونی می‌مانند. شبکه مقادیر Q را برای نامزدهای قانونی محاسبه می‌کند و در این نمونه:

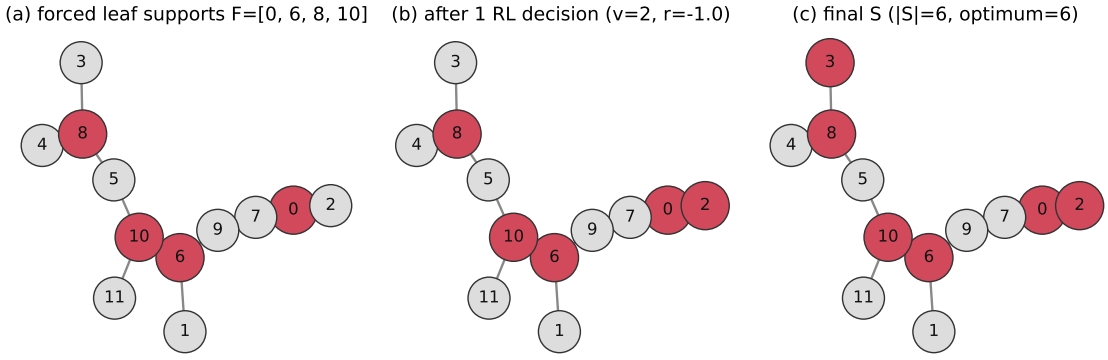
$$Q(2) = -3.732, \quad Q(3) = -3.767, \quad Q(4) = -3.767.$$

بیشینه، رأس 2 است؛ پس عمل $a_1 = 2$، رأس 0 راضی می‌شود $(vf_0 : 0 \to 1)$ و پاداش $r = -1$ دریافت می‌شود (تعریف ۱-۲). شکل ۱-۱۲ (ب).

گام دو. نامزدها اکنون $\{1,3,4,5,7,9,11\}$ هستند و سود بیشینه برای $\{3,4,5\}$ برابر 1 است. شبکه $Q(3) = -1.884$ را بیشینه می‌بیند و $a_2 = 3$ انتخاب می‌شود؛ رأس 8 راضی می‌شود و پاداش باز هم -1 است.

پایان. پس از این دو تصمیم، همه رأس‌ها $vf = 1$ دارند و شرط پایان برقرار است. مجموعه نهایی $S = \{0,2,3,6,8,10\}$ با اندازه 6 است که با $\gamma_t = 6$ (حل دقیق) برابر است. سیاست حریصانه بومی نیز همین اندازه را می‌دهد، اما GRASP و هر دو سیاست مدل روی این نمونه به بهینه رسیدند؛ نکته اصلی صرفه‌جویی در تصمیم است: عامل فقط دو تصمیم گرفت، در حالی که بدون F باید شش تصمیم می‌گرفت. شکل ۱-۱۲ (ج).

حسابداری پاداش. اگر پاداش سود به‌کار می‌رفت، مجموع آن در این اپیزود دقیقاً $n = 12$ می‌شد و هیچ ارتباطی با $|S| = 6$ نداشت (قضیه ۱-۳). با پاداش هزینه، بازده تصمیم‌های عامل -2 است و با احتساب $|F| = 4$ مجموعه‌ای، بازده کل باز هم $-|S| = -6$ می‌شود؛ یعنی بازده دقیقاً همان تابع هدف است.



شکل ۱-۱۲: اجرای گام‌به‌گام روی درخت $n = 12$: (الف) نشاندن F؛ (ب) پس از یک تصمیم شبکه؛ (ج) مجموعه نهایی.

۱-۱۲ تهدیدهای اعتبار

۱. تعداد تکرار روی گراف‌های تصادفی: برای ER و BA تنها ۱۰ نمونه در هر اندازه تولید شده است (کمتر از آزمایش‌های فصل چهارم که ۲۰ نمونه داشت). لتیس‌ها تک‌نمونه‌اند و نتیجه‌گیری قوی روی مثلثی مجاز نیست (تنها یک نمونه).

۲. حل دقیق فقط تا $n \leq 120$: بنابراین برای گراف‌های BA/ER با $n = 300$ و درخت‌ها با $n = 200$، معیار γ_t

در دسترس نیست و مقایسه فقط با خط مبنای حریصانه انجام شده است.

۳. تک□□□□ بودن مدل‌های متراکم: $size - v2$ و $paper - v2$ فقط با یک □□□□ آموزش دیده‌اند؛ سه-□□□□ فقط برای دو بازوی اسپارس انجام شده است. بنابراین ادعای «کیفیت» روی این دو checkpoint به □□□□ حساس است و در متن با همین قید نقل می‌شود.

۴. معیار آستانه‌ای همگرایی: عدد «1.7 برابر سریع‌تر» برای D3QN بر پایه رسیدن به یک سطح آستانه تعریف شده و به انتخاب سطح فلات حساس است.

۵. □□□-□□□□ قطعی: در ارزیابی، تصمیم‌گیری روی مقادیر Q و بدون نمونه‌گیری انجام می‌شود؛ بنابراین نوسان تصادفی در نتایج آزمایش وجود ندارد و تنها منبع تصادفی، خودِ نمونه‌های گراف و کنترل random@k است.

فصل ۲

نتیجه‌گیری و پیشنهادها

۲-۱ خلاصه مسیر انجام پژوهش

این پژوهش با بازسازی دقیق چارچوب Chen و همکاران آغاز شد: شبکه عصبی پیام‌رسان برای استخراج نمایش گراف، DDQN برای تصمیم‌گیری متوالی، و یک محیط پوشش‌محور که در هر گام یک رأس را انتخاب می‌کند. بازسازی انجام شد و نتایج مقاله روی جدول‌های مرجع بازتولید گردید؛ اما بازسازی تنها نقطه شروع بود. مسیر اصلی پژوهش سه مرحله داشت:

۱. بررسی تعمیم‌پذیری چارچوب: آیا اجزای روش مرجع را می‌توان به مسئله سخت‌گیرانه‌تر مجموعه احاطه‌گر کامل منتقل کرد؟

۲. بهبود چارچوب برای مسئله هدف: بازطراحی فضای عمل، بازتعریف تابع پاداش، رفع یک باگ مقیاس‌پذیری در معماری، و به‌کارگیری دانش نظریه گراف.

۳. رقابت با روش‌های غیریادگیری: مقایسه با خط پایه حریصانه و بازارزیابی GRASP با معیارهای کیفیت، شدنی‌بودن، زمان و همگرایی.

۲-۲ پاسخ به سؤالات تحقیق

۲-۳ مشارکت‌های پژوهش

۱. قضیه ناسازگاری ماسک و نمونه نقض کمینه: نشان داده شد که ماسک عمل چارچوب مرجع، ذاتاً (و نه به‌دلیل ضعف آموزش) ناتوان از تولید جواب برای TDSP است؛ این نتیجه با اثبات ریاضی، با ۱۷۷ آزمایش محاسباتی و با مثال نقض P_4 پشتیبانی می‌شود.

۲. محیط بازطراحی‌شده با حالت دوکاناله: قاعده گذار جدید (انتخاب v تنها $N(v)$ را راضی می‌کند) به‌همراه حالت $[vf, ins]$ و پاداش هزینه، مسئله را بدون تغییر در حلقه یادگیری و شبکه قابل حل کرد.

جدول ۲-۱: پاسخ فشرده به سؤالات پژوهش و شاهد هر پاسخ

سؤال	پاسخ	شاهد
آیا بازتولید نتایج مقاله با دقت قابل قبول ممکن است؟	بله؛ تعریف جدول‌های مرجع بازتولید و انحراف‌ها ثبت شد	فصل چهارم و جداول مرجع
آیا مفاهیم نظریه گراف فضای جست‌وجو را کاهش می‌دهند؟	بخشی: اجبار برگ‌ها تصمیم‌ها را حدود ۶۴٪ کم می‌کند؛ اما قواعد کاهش کلاسیک در این دامنه فعال نمی‌شوند	بخش ۱-۷، جدول ۱-۲
آیا می‌توان فرآیند یادگیری را بهبود داد؟	بله؛ اجبار برگ‌ها همگرایی را حدود ۵.۳ برابر سریع‌تر و سر دوگانه آن را حدود ۷.۱ برابر سریع‌تر می‌کند	شکل ۱-۶
آیا کیفیت پاسخ رقابتی است؟	هم‌سطح با GRASP با اختلاف آماری ناچیز، و برتری معنادار روی لاتیس شش‌گوش؛ اما روی BA بازنده	جدول ۱-۳، شکل ۱-۱۰
آیا چارچوب به TDSP تعمیم‌پذیر است؟	بله؛ اما نه با ماسک مقاله؛ نیازمند بازطراحی فضای عمل (قضیه ۱-۲)	بخش ۱-۳، شکل ۱-۲
وضعیت زمان اجرا چگونه است؟	۴ تا ۲۵ برابر سریع‌تر از GRASP با کیفیت هم‌سطح	شکل ۱-۱۱

۳. اصلاح باگ مقیاس‌پذیری خوانش گراف: تشخیص اینکه جمع‌کردن نمایش رأس‌ها باعث انفجار مقادیر Q با n می‌شود، و اصلاح آن با تجمیع میانگین؛ این اصلاح کیفیت روی گراف‌های بزرگ را از 4.34 به 1.04 رساند.

۴. اجبار برگ‌ها به‌جای حذف آن‌ها: تبدیل یک قاعده کاهش نامعتبر (که با مثال P_3 رد می‌شود) به یک راهبرد معتبر و مؤثر، با اثبات درستی و اندازه‌گیری اثر روی کیفیت و همگرایی.

۵. دو تقویت صفر-آموزش: پالایش خروجی مبتنی بر مشاهده هم‌ارزی TDSP با مسئله پوشش مجموعه‌ای، و ماسک top-k سودمحور، هر دو بدون هیچ آموزش تازه و با اثبات حفظ شدنی‌بودن.

۶. پروتکل ارزیابی چند-□□□□ و زوجی: تکرار آموزش با سه □□□□ و مقایسه زوجی (همان ،□□□□ دو پیکربندی) که نشان داد اثر اجبار نقطه پایان را تغییر نمی‌دهد و تنها سرعت رسیدن به آن را عوض می‌کند.

۲-۴ قلمرو روش: کجا مفید است و کجا نیست

جمع‌بندی نتایج، تصویر دقیقی از جایگاه روش ارائه می‌دهد که برای استفاده عملی ضروری است:

- برنده: لاتیس شش‌گوش و خانواده‌های اسپارس (درخت، BA با $m = 1$). روی شش‌گوش، مدل با تقویت‌ها از GRASP بهتر است (0.786 در برابر 0.847) و روی اسپارس کیفیت بهینه است.
- هم‌سطح: شبکه مستطیلی، مثلثی و ER؛ اینجا مسئله اشباع شده و فاصله معناداری میان روش‌ها وجود ندارد.

- بازنده: گراف‌های BA متراکم، که GRASP در آن‌ها بهتر است. دستیابی به برتری در این خانواده نیازمند آموزش چنداندازه و بودجه محاسباتی بیشتر است.
- مزیت پایدار روش: زمان استنتاج ثابت و کوچک. مدل یک بار آموزش می‌بیند و سپس با یک گذر شبکه‌ای جواب می‌دهد؛ این ویژگی در کاربردهای بی‌درنگ (شبکه حسگر، تخصیص منابع) که مسئله باید مکرر و سریع حل شود، ارزش عملی دارد.

۵-۲ محدودیت‌ها

محدودیت‌های اصلی همان‌هایی است که در بخش ۱-۱۲ فهرست شد: تعداد محدود تکرار روی گراف‌های تصادفی، در دسترس نبودن حل دقیق برای $n > 120$، آموزش تک□□□□ برای دو checkpoint متراکم، حساسیت معیار همگرایی به سطح آستانه و قطعی بودن roll-out در ارزیابی. افزون بر این‌ها، سه محدودیت روش‌شناختی را باید صریح اعلام کرد:

۱. بخشی از آزمایش‌ها روی سخت‌افزار متفاوت (واحد پردازش گرافیکی و پردازنده مرکزی) اجرا شده است. پروتکل و □□□□ یکسان بوده، اما دنباله اعداد تصادفی در این دو محیط یکی نیست؛ بنابراین آن دو اجرا کپی بیتی یکدیگر نیستند و مقایسه در سطح پروتکل انجام شده است.

۲. گزارش مقاله مرجع برای هر اندازه گراف یک مدل جداگانه آموزش می‌دهد؛ در این پژوهش نیز برای هم‌خوانی همان رویه دنبال شد، اما در آزمایش‌های اسپارس یک مدل واحد روی چند اندازه آزمون شد که طبیعتاً سخت‌گیرانه‌تر است.

۳. ادعاهای کیفیت روی گراف‌های تصادفی به میانگین نمونه محدود است؛ در لتیس‌ها اندازه نمونه کوچک است و نتایج آن‌ها را نباید تعمیم داد.

۶-۲ پیشنهادهای کارهای آینده

۱. الگوریتم‌های جایگزین: ارزیابی روش‌های روی‌سیاستی مانند PPO که با حذف replay buffer تعریف حافظه مقاله را زیر سؤال می‌برند، و شبکه‌های گرافی قوی‌تر مانند GIN برای مقایسه دقیق‌تر توان نمایش.

۲. آموزش چنداندازه: تعلیم یک مدل روی ترکیبی از اندازه‌ها و خانواده‌ها، برای آزمون برتری روی BA و گراف‌های بزرگ‌تر؛ این مسیر در فضای CPU گران است و اجرای موازی یا استفاده از شتاب‌دهنده توصیه می‌شود.

۳. ترکیب یادگیری و جست‌وجو: به‌کارگیری خروجی شبکه به‌عنوان جواب اولیه برای جست‌وجوی محلی یا برنامه‌ریزی محدود (look-ahead)؛ چون خروجی مدل از پیش شدنی است، بهبودهای جزئی روی آن ارزان هستند.

۴. تعمیم به اهداف ترکیبی: نسخه‌های وزن‌دار (k-domination) یا احاطه‌گری با محدودیت بودجه، که در آن‌ها یک چارچوب یادگیری‌محور با سرعت استنتاج ثابت مزیت بیشتری نشان می‌دهد.

۵. ارزیابی احتمال‌محور: گزارش بازه اطمینان روی همه ادعاهای کیفیت و افزودن های□□□□ بیشتر برای مدل‌های متراکم، تا نتایج در برابر انتخاب تصادفی مقاوم شوند.

۶. مطالعه اثر معماری سر شبکه: بررسی اینکه آیا ترکیب ماسک top-k با سرهای پیشرفته‌تر (مثل سر مزیت تفکیک‌شده چندلایه) می‌تواند آن 11 واحد فاصله با سیاست تصادفی را در خانواده‌های متراکم نیز به برتری نسبت به خط مبنا تبدیل کند.

منابع

واژه‌نامه فارسی به انگلیسی

Persian	English
احاطه‌گر مجموعه	Dominating Set
کامل احاطه‌گر مجموعه	Total Dominating Set
گراف عصبی شبکه	Graph Neural Network
پیام‌رسان عصبی شبکه	Message Passing Neural Network
تقویتی یادگیری	Reinforcement Learning
بازپخش حافظه	Experience Replay Buffer
تصادفی حریصانه بازارزیابی	GRASP
دوگان سر	Dueling Head
مجموعه‌ای پوشش	Set Cover